單擺實驗數據分析與擬合

目標

單擺實驗不僅僅是對古典力學現象的重現，此講義將進一步引導同學建立嚴謹的數據分析、誤差評估以及物理模型擬合能力。我們將探討如何利用數據分析驗證單擺運動的理論模型，利用擬合方法（Fitting）估算重力加速度值，並藉由 Chi-squared χ^2 統計量（含 reduced chi）與殘差分析（Residual Analysis）來評估擬合品質與探討系統性誤差。

- 本單元沒有要求同學要完全自己寫出 python code，而是藉由詳盡清楚的提示詞（prompt） 讓 AI 寫出你需要的程式，且能用物理邏輯判斷輸出結果是不是正確。
- 安裝 python 請見補充資料 (python set up tutorial)。建議安裝 python 有問題或是沒有 python 經驗的同學使用 google colab。
- 講義原理簡介部分有兩題問題，記得回答。
- 實驗記錄簿如何撰寫請務必看**實驗記錄簿規範：python**

指定閱讀

- 呂浩宇老師講義 part1 and part2 https://github.com/baobabyoo/Lecture_DataAnalysis
- 補充講義 Python_ch1, Python_ch2 有提供範例作為編寫程式的參考。
- **實驗記錄簿規範：python**

預習問題

1. 為何在小角度近似條件下，單擺的週期 T 與擺長 L 之間的關係可以表示為 T = 2π (L/g)^1/2 ？請說明這個公式的推導過程。
2. 透過對數變換，單擺的週期與擺長的關係可以轉換成線性關係。請寫出這個轉換過程，並解釋為何這樣的轉換可以幫助我們利用線性擬合來求解重力加速度 g。
3. 最小平方法 (least square fitting) 擬合的基本原理是甚麼? Python 中 curve_fit 的預設值是用最小平方法 (least square fitting) 嗎?
4. Chi-square (χ^2) 擬合的基本原理是什麼？與最小平方法 (least square fitting) 擬合有何不同？
5. 如何計算 χ^2 值？請寫出計算公式並說明其中的每一個變數代表的意義。
6. 誤差大致上可分為哪兩類 (並列出其中細項)? 哪一類的誤差可以透過進行多次實驗來減少誤差?

原理簡介

1. 數據建模：頻率學派與貝氏推論

在擁有數據後，我們必須建立數學模型來描述它。建立數據模型（Modeling data）的目的主要有二：一是簡化描述（Simplifying the description），例如將一組龐雜的測量數據簡化為具有特定平均值與標準差的高斯分佈；二是限制物理參數與理解物理原理（Constraining physical parameters），例如透過比較理論模型與數據來限縮重力加速度的合理範圍 。處理數據時，研究者應具備明確知曉操作意圖、具備解釋能力、確保可重現性（Reproducibility）。

在現代科學推論中，主要存在兩種不同的統計哲學：貝氏推論（Bayesian Inference）與頻率學派推論（Frequentist Inference）。理解這兩者的差異，對於大二物理系學生跨入進階數據分析至關重要[1]。

1.1 貝氏推論：結合先驗知識的機率模型

貝氏推論由基本的機率公理出發，其核心在於處理「當取得特定數據時，某個模型為真的機率」，即描述完整的後驗機率分佈 (poster model probability) $P((\text{model}|\text{data}))$ 。根據貝氏定理，這可以展開為：

$$P(\text{model}|\text{data}) = \frac{P(\text{data}|\text{model})P(\text{model})}{P(\text{data})}$$

在這裡， $P(\text{model})$ 稱為先驗機率（Prior model distribution），代表在看到實驗數據前，我們基於初步物理知識或過去經驗對模型成立機率的假設。$P((\text{data}|\text{model}))$ 稱為似然函數 (Likelihood)，表示在某特定模型或參數為真的情況下，觀察到這組實驗數據的機率。而分母 $P(\text{data})$ 稱為證據 (Prior predictive probability)，在某些情況下可視為使總機率為 1.0 的正規化常數。

舉一個直觀的例子：假設已知男女在大二實驗課中得分的機率分佈。當 10 個學生中，100 分有 3 人、50 分有 5 人、0 分有 2 人，問此 10 人最可能的性別分佈為何？在貝氏推論中，我們可以利用「物理系女生僅佔 20%」這個已知情報作為先驗機率（Prior），並結合得分的 Likelihood，計算出最精確的後驗機率。這正是貝氏推論處理複雜問題（如近代物理常用之馬可夫鏈蒙地卡羅方法 Markov chain Monte Carlo）的強大之處[1]。

1.2 頻率學派推論與最大概似分析

然而，在許多物理實驗的實作中，我們往往對問題一無所知，難以真正給出一個合理且毫無爭議的先驗機率 $P(\text{model})$ 。此時，物理學家經常採用頻率學派推論。頻率學派

處理的問題，是在無法得知先驗機率的情形下，直接尋找一組模型參數，使得當下這組實驗數據出現的機率 $P(\text{data}|\text{model})$ 達到極大化。

這正是最大概似分析（Maximum Likelihood Analysis）與最小平方法（Least Square Analysis）的核心思想。我們預設自然界的量測誤差會因為眾多獨立隨機因素的疊加，根據中央極限定理（Central Limit Theorem），最終傾向於服從高斯分佈（Gaussian distribution）[10]。頻率學派的初步工作，就是調整模型參數使得這個高斯似然函數達到極大值 。

問題： 在單擺實驗中，我們不知道當地的精確重力加速度，因此我們尋找一個 g 值，讓「測量出這組週期數據」的機率達到最大。請問這屬於貝氏推論還是頻率學派推論？如果我們事先查閱文獻，知道當地的 g 值應為 9.80$\pm$0.01 m/s^2，並將此資訊納入數據分析中以修正我們的預測，這又屬於哪一種推論？

2. 核心原理解析：從高斯誤差到 χ^2 最小化

對於大二物理系學生而言，最大的認知斷層往往在於：為什麼我們在實驗室中常常要「最小化 χ^2」？這究竟是數學上的巧合，還是物理上的必然？實際上，這兩者是同源的。本節將詳細解釋從「高斯誤差」到「χ^2 最小化」的邏輯推演，這也是將講義原理無縫整合的核心段落。

2.1 測量誤差的理論建模：$f(x\,;a)$ 表示法

在資料擬合中，我們常把理論模型寫成 $f(x_i;a)$ 或 $f(x_i;a,\ b)$ 。這裡的分號「;」不是新的數學運算，而是用來強調：分號前面的 x_i 是自變數或已知輸入（例如單擺實驗中由實驗者設定的擺長 a），而分號後面的 a 則是模型參數（需要由實驗資料擬合來決定的未知數，例如線性化後的斜率 a，或最後換算出的重力加速度 g）。

因此， $f(L;a)$ 可以讀成：「在參數 a 這個給定值之下，理論模型對輸入擺長 L 所做出的週期預測」。

對每個實驗資料點 i，我們假設儀器量到的數值 y_i 可以寫成「理論預測值 + 隨機雜訊」的組合[1]：

$$y_i = f(x_i;a) + \epsilon_i$$

其中 ϵ_i 是由量測造成的隨機誤差。

2.2 關鍵假設：誤差服從獨立高斯分佈

在絕大多數巨觀物理實驗中，隨機誤差 ϵ_i 的來源眾多（例如氣流微擾、溫度微小起伏、

人為視覺判斷等）。根據中央極限定理，這些微小且獨立的干擾疊加後，其總誤差 ϵ_i 極高機率可近似為服從常態分佈（高斯分佈），且平均值為 0、變異數為 σ_i^2 。我們記為 $\epsilon_i \sim \mathrm{N}(0, \sigma_i^2)$ [2]。

在給定模型參數 a 的前提下，單一數據點 y_i 出現的機率密度函數（Probability Density Function, PDF）可寫成高斯函數的形式[1]： $P(y_i|a) = \frac{1}{\sqrt{2\pi\sigma_i^2}} \exp\left[-\frac{(y_i - f(x_i;\, a))^2}{2\,\sigma_i^2}\right]$

若各點的量測誤差彼此獨立，那麼整組資料（共 N 個點）同時出現的聯合機率密度，就是所有單一點機率的連乘積。這個連乘積被稱為「似然函數（Likelihood Function）」，記作 $L(a)$ [1]：

$$L(a) = \prod_{i=0}^{N-1} P(y_i|a) = \prod_{i=0}^{N-1} \left(\frac{1}{\sqrt{2\pi\sigma_i^2}} \exp\left[-\frac{(y_i - f(x_i;\, a))^2}{2\,\sigma_i^2}\right]\right)$$

這個 $L(a)$ 的物理意義在於：把已經發生的實驗資料固定下來，把未知的參數 a 當作變數，詢問「到底是哪一組參數 a，能讓這組實驗資料出現的機率最大？」這就是頻率學派的最大概似估計（Maximum Likelihood Estimation）[1]。

2.3 對數轉換與 χ^2 的誕生

由於連乘積中包含了極多指數項，直接微分求極值在數學上極其困難。幸運的是，自然對數 ln 是一個單調遞增的函數，因此「最大化似然函數 $L(a)$」與「最大化其對數 $\ln L(a)$」在數學上完全等價，並會給出相同的最佳參數解[1]。

取自然對數有兩個極大的好處：第一，ln 會把連乘積變成連加總；第二，ln(exp(.)) 會把高斯分佈的指數括號「拉下來」。對整個似然函數取對數後可得[1]：

$$\ln L(a) = \sum_{i=0}^{N-1} \ln\left(\frac{1}{\sqrt{2\pi\sigma_i^2}}\right) - \frac{1}{2}\sum_{i=0}^{N-1}\left(\frac{y_i - f(x_i;a)}{\sigma_i}\right)^2$$

觀察上式，第一項的加總完全不包含待求參數 a（因為正規化項只依賴量測完成後已知的 σ_i 與常數 2π，不隨 a 改變）。因此在對 a 微分尋找極值時，這個常數項會直接消失，可完全忽略。

於是，要讓 $\ln L(a)$ 達到最大值，就等同於要讓第二項中被減去的加總項達到「最小值」。物理學家將這個需要被最小化的加總項定義為 $\chi^2(a)$（Chi-squared）[1]：

$$\chi^2(a) = \sum_{i=0}^{N-1} \left(\frac{y_i - f(x_i; a)}{\sigma_i} \right)^2$$

這段推導完美地將「高斯誤差的最大概似估計」與我們熟知的「χ^2 擬合」連接在一起：**在高斯誤差的假設下，最合理（最大概似）的模型參數，正是能讓 χ^2 最小的那組參數**[1]。

2.4 背景知識練習題：χ^2 的本質

問題： 從 χ^2 的數學定義中，每個殘差平方都被除以了 σ_i^2。這與單純計算殘差平方和（$\sum(y_i - f(x_i))^2$）的最小平方法有何物理意義上的差異？這會對最終的擬合直線產生什麼影響？

3. 線性擬合實作：以 χ^2 最小化推導最佳參數與不確定度

理解了 χ^2 的來源後，我們接著探討如何將其應用於單擺實驗的線性化數據。當單擺公式轉換為線性模型 $y = ax + b$ 後，我們可以透過解析方法推導出最佳斜率 a 與截距 b，並利用誤差傳播推導其不確定度[1]。

3.1 尋找最佳擬合參數的解析解

我們將線性模型代入 χ^2 的定義中，此時 χ^2 是一個同時依賴於參數 a 與 b 的函數[1]：

$$\chi^2(a, b) = \sum_{i=0}^{N-1} \left(\frac{y_i - ax_i - b}{\sigma_i} \right)^2$$

在微積分中，尋找函數的極小值意味著對變數求偏微分並令其等於零。因此，我們對 a 和 b 分別求偏微分[1]：

$$\frac{\partial \chi^2}{\partial a} = -2 \sum_{i=0}^{N-1} \frac{x_i(y_i - ax_i - b)}{\sigma_i^2} = 0$$

$$\frac{\partial \chi^2}{\partial b} = -2 \sum_{i=0}^{N-1} \frac{(y_i - ax_i - b)}{\sigma_i^2} = 0$$

為了簡化這些繁瑣的求和符號，我們定義一系列的「加權數據總和」變數：

$$S \equiv \sum_{i=0}^{N-1} \frac{1}{\sigma_i^2}, \quad S_x \equiv \sum_{i=0}^{N-1} \frac{x_i}{\sigma_i^2}, \quad S_y \equiv \sum_{i=0}^{N-1} \frac{y_i}{\sigma_i^2}$$

$$S_{xx} \equiv \sum_{i=0}^{N-1} \frac{x_i^2}{\sigma_i^2}, \quad S_{xy} \equiv \sum_{i=0}^{N-1} \frac{x_i y_i}{\sigma_i^2}$$

將這些定義代回偏微分方程式，我們得到了一組二元一次聯立方程式（Normal Equations）[1]：

$$\begin{cases} bS + aS_x = S_y \\ bS_x + aS_{xx} = S_{xy} \end{cases}$$

透過克拉瑪公式或矩陣代數解此聯立方程式，並定義行列式 $\Delta \equiv SS_{xx} - (S_x)^2$ ，即可求得最佳擬合參數 a 與 b 的解析解[1]：

$$a = \frac{SS_{xy} - S_x S_y}{\Delta}$$

$$b = \frac{S_{xx} S_y - S_x S_{xy}}{\Delta}$$

由於這組解析解對離群值（Outliers）極度敏感（如果某個點的 σ_i 極小但數值偏離極大，它會嚴重影響所有的 S 總和），在更進階的分析中可以引入強健估計（Robust Estimation）來緩解這個問題[1]。

3.2 參數的不確定度與誤差傳播

獲得了 a 與 b 後，物理實驗的另一半任務是給出這些參數的不確定度（Uncertainty）。在統計學的概念中，我們將擬合出的參數 a 與 b 視為所有測量值 y_i 的函數。也就是說，個別 y_i 的隨機微小波動 δy_i，會連帶引起參數 a 與 b 的波動[1]。

對於任意函數 $f(y_0, y_1, \dots y_{N-1})$ ，假設所有的測量彼此獨立（其協方差 $E[\delta y_i \delta y_j] = 0$ 若 $i \neq j$，且等於 σ_i^2 若 $i = j$），我們可以利用泰勒展開式的線性項推導出標準的誤差傳播定律（Error Propagation Law）[1]：

$$\sigma_f^2 \equiv \mathrm{Var}(f(y)) = E[(f(y) - f(y_{\mathrm{true}}))^2] \approx \sum_{i=0}^{N-1} \sigma_i^2 \left(\frac{\partial f}{\partial y_i}\right)^2$$

為了計算斜率 a 的誤差 σ_a^2 ，我們需要對先前求得的 a 解析解公式，針對每一個數據點

y_i 求偏導數[1]：

$$\frac{\partial a}{\partial y_i} = \frac{\partial}{\partial y_i}\left(\frac{SS_{xy} - S_x S_y}{\Delta}\right) = \frac{S\frac{x_i}{\sigma_i^2} - S_x\frac{1}{\sigma_i^2}}{\Delta} = \frac{Sx_i - S_x}{\sigma_i^2\Delta}$$

同理可得：

$$\frac{\partial b}{\partial y_i} = \frac{S_{xx} - S_x x_i}{\sigma_i^2\Delta}$$

將這兩個偏導數代回誤差傳播定律的求和公式中，經過代數整理，我們會得到極其簡潔且優雅的最終結果[1]：

$$\sigma_a^2 = \frac{S}{\Delta}$$

$$\sigma_b^2 = \frac{S_{xx}}{\Delta}$$

透過這兩條公式，我們不僅算出了最佳擬合直線的斜率與截距，更嚴謹地量化了這條直線的誤差範圍，這為後續推導重力加速度 $g \pm \sigma_g$ 奠定了數學基礎。

3.3 擴展至一般線性問題與矩陣演算法

前述推導是針對簡單的一條直線。但若物理模型更複雜，例如多項式擬合 $y(x) = a_0 + a_1x + a_2x^2 + \cdots$，或者是利用傅立葉級數等基底函數（Basis functions）展開時，只要待求參數 a_k 與應變數之間是線性組合的關係，這類問題統稱為「一般線性問題（General linear problem）」。

我們可以將一般線性模型寫成 M 個基底函數 $X_k(x)$ 的線性組合：$y(x) = \sum_{k=0}^{M-1} a_k X_k(x)$。對其建構 χ^2 函數並對每個參數 a_k 求偏微分令為零，會得到一個 $M \times M$ 的線性聯立方程組 。 為了用計算機高效求解，我們定義設計矩陣（Design Matrix）衍生的元素 α_{kj} 與向量 β_k[1]：

$$\alpha_{kj} = \sum_{i=0}^{N-1} \frac{X_j(x_i)X_k(x_i)}{\sigma_i^2}, \quad \beta_k = \sum_{i=0}^{N-1} \frac{y_i X_k(x_i)}{\sigma_i^2}$$

整個聯立方程組可寫為簡潔的矩陣形式：$\overleftrightarrow{\alpha} \cdot a = \beta$。 在實作中，我們只需計算矩陣 α 的反矩陣 $C = \alpha^{-1}$ 。這個矩陣 C 稱為「協方差矩陣（Covariance Matrix）」，最佳參數解為 $a = C \cdot \beta$[1]。

在推導參數不確定度時，我們同樣運用誤差傳播定律。經過複雜的矩陣偏微積分推導，會得到一個極為關鍵的結論：**任何一個擬合參數 a_j 的方差 σ_a^2 ，恰好等於協方差矩陣 C 主對角線上對應的元素 C_{jj}** [1]。 如果矩陣 α 是奇異矩陣（Singular Matrix，即反矩陣不存在），代表方程組無唯一解，這種情況通常表示物理模型過度參數化或基底函數彼此線性相依。此時必須應用「奇異值分解（Singular Value Decomposition, SVD）」演算法來進行極端情形下的求解 [1]。

數據分析

請匯入助教所提供的實驗數據，開始進行分析。可以參考補充資料 ch2 講義中的 practice。

- curve_fit 核心功能與基礎語法

curve_fit 函數的基礎調用邏輯如下 [3]：

```
import numpy as np
from scipy.optimize import curve_fit

# 1. 定義物理模型函數 (以線性模型為例)
def linear_model(x, a, b):
    return a * x + b

# 2. 呼叫 curve_fit 進行擬合
popt, pcov = curve_fit(linear_model, x_data, y_data, sigma=y_errors, absolute_sigma=True)
```

此函數接收模型、自變數資料、應變數資料，以及關鍵的資料點不確定度 sigma 陣列。它會回傳兩個核心物件 [4]：

- **popt** (Optimal parameters)：使 χ^2 最小化的最佳參數陣列（即推導出的 a 與 b）。
- **pcov** (Covariance matrix)：如第 3.3 節所述的協方差矩陣。參數的標準差（誤差）可透過取其對角線元素的平方根提取：perr = np.sqrt(np.diag(pcov)) [1]。

- absolute_sigma 參數的物理意義

當我們在 curve_fit 中傳入 sigma=y_errors 時，我們期望它執行標準的 χ^2擬合。然而，curve_fit 內部對待 sigma 的方式取決於另一個布林參數 absolute_sigma，而它的預設值是 False [3]。

1. 當 absolute_sigma = False（預設值）：Python 僅將傳入的 sigma 視為「相對權重（Relative weights）」。演算法在計算出初始的協方差矩陣後，會在背後強行乘上一個常數縮放因子，這個因子的數學意義是強迫讓縮減卡方 χ_ν^2 變成 1.0 。
2. 當 absolute_sigma = True (正確的物理實作法)： 將此參數設為 True，會強制 curve_fit 將傳入的 sigma 陣列視為真正的物理量絕對標準差（Absolute standard deviations）。此時，回傳的協方差矩陣 pcov 才會真實反映 χ^2 空間的曲率，其對角線所算出的參數誤差才是具備物理統計意義的真實不確定度 。

問題與討論

1. 根據實驗數據的擬合結果所計算出的 χ^2 值是多少? 如何利用 χ^2 值判定擬合的好壞? 如果值偏差較大，可能有哪些原因？
2. 在數據擬合過程中，測量誤差 (error bar) 的值會如何影響 χ^2 值和最終擬合的重力加速度 g？
3. 殘差圖是否呈現隨機分佈？是否觀察到某種趨勢（例如隨擺長增加或減少)？如果存在系統性誤差，可能的原因是什麼？如何改進實驗設計來減少這類誤差?
4. χ^2 擬合的結果與單純使用最小平方法 (least square fitting) 擬合相比有何不同？ χ^2 擬合的優勢在哪裡？適合用在什麼實驗？

Reference

1. https://github.com/baobabyoo/Lecture_DataAnalysis/tree/main/lecture_notes
2. https://stats.stackexchange.com/questions/23479/why-do-we-assume-that-the-error-is-normally-distributed
3. https://docs.scipy.org/doc/scipy/reference/generated/scipy.optimize.curve_fit.html
4. SciPy curve fitting, accessed February 28, 2026, https://web.physics.utah.edu/~detar/lessons/python/curve_fit/node1.html